Analisis Trade-off antara Akurasi dan Efisiensi Komputasi dalam Deteksi Sarkasme Menggunakan DistilBERT dan RoBERTa

Falah Razan Hibrizi
Fakultas Informatika
Universitas Telkom
Bandung, Indonesia
alamat email

Nama Pembimbing
Fakultas Informatika
Universitas Telkom
Bandung, Indonesia
alamat email

***Abstrak*—Sarkasme sering menyatakan maksud yang berlawanan dengan arti harfiahnya, sehingga sistem analisis sentimen kerap salah membaca kalimat sarkas. RoBERTa dikenal akurat tetapi mahal secara komputasi, sementara DistilBERT menawarkan model yang lebih kecil. Penelitian ini mengkaji trade-off antara performa dan efisiensi komputasi kedua model menggunakan 1.000.864 pasangan comment dan parent comment dari Self-Annotated Reddit Corpus (SARC). Perbandingan mencakup tiga konfigurasi input, yaitu comment saja, early fusion, dan late fusion, serta pembekuan sebagian layer. Konfigurasi final ditentukan dari data validasi dan dikunci sebelum skor data uji dihitung. Setiap konfigurasi dijalankan dengan tiga seed, lalu diuji menggunakan paired t-test, Wilcoxon signed-rank test, dan Friedman test dengan koreksi Holm. Macro-F1 tertinggi sebesar 79,62% diperoleh RoBERTa dengan early fusion, dan pada ketiga input RoBERTa unggul 1,65–2,07 poin dibanding DistilBERT. Meski begitu, DistilBERT masih mencapai 97–98% macro-F1 RoBERTa, sedangkan waktu training, latensi, dan memori GPU-nya hanya sekitar setengah. Penambahan parent comment menaikkan macro-F1 sebesar 0,69–1,10 poin, dengan kenaikan terbesar pada comment yang ambigu. Pada RoBERTa, early fusion lebih akurat dan jauh lebih hemat daripada late fusion. Pembekuan 6 dari 12 layer RoBERTa hanya mengurangi macro-F1 sebesar 0,24 poin dan memangkas waktu training sekitar 45%, walaupun latensi inferensi tidak ikut turun. Berdasarkan hasil tersebut, RoBERTa lebih tepat dipakai bila akurasi diutamakan, sedangkan DistilBERT lebih tepat untuk kondisi dengan batasan latensi dan memori.**

***Kata Kunci*—DistilBERT, deteksi sarkasme, efisiensi komputasi, parent comment, pembekuan layer, RoBERTa**

I. PENDAHULUAN

Dalam sarkasme, penutur mengatakan sesuatu yang berbeda, bahkan berlawanan, dengan maksud sebenarnya. Sebuah pujian, misalnya, dapat dipakai untuk mengejek. Kalimat semacam ini sulit ditangani oleh sistem analisis sentimen karena kata-kata yang terlihat positif ternyata membawa maksud negatif [1]. Akibatnya, sistem pemantau opini publik dan moderasi konten dapat memberikan hasil yang keliru, termasuk ketika digunakan untuk mendeteksi perundungan siber di media sosial [2], [3].

Kesulitan ini bertambah pada teks tertulis, karena tidak ada nada suara maupun ekspresi wajah yang dapat dijadikan petunjuk [4]. Di forum seperti Reddit, sifat sarkas sebuah balasan sering kali baru terlihat setelah pembaca mengetahui komentar yang dibalas, yang disebut parent comment. Self-Annotated Reddit Corpus (SARC) [5] menyediakan pasangan parent comment dan balasan dalam jumlah sangat besar. Konteks lain, seperti informasi pengguna dan topik forum, juga membantu model pada SARC [6]. Beberapa penelitian pada data percakapan Reddit melaporkan bahwa memasukkan parent comment ke dalam input model transformer dapat menaikkan performa deteksi sarkasme [7], [8].

Saat ini, model berbasis transformer banyak digunakan untuk tugas tersebut. RoBERTa [9] merupakan pengembangan BERT dengan prosedur pralatih yang diperbaiki. Model ini umumnya menghasilkan akurasi tinggi, tetapi kebutuhan memori dan waktu komputasinya juga besar, padahal sumber daya komputasi terbatas [10]. DistilBERT [11] dihasilkan melalui distilasi pengetahuan, sehingga jumlah layernya tinggal setengah dari BERT dan proses inferensinya lebih cepat. Studi yang membandingkan varian BERT untuk deteksi sarkasme menunjukkan bahwa performa sangat bergantung pada pilihan model dan pengaturan training [4], [12].

Perbandingan langsung antara RoBERTa dan DistilBERT, termasuk pada SARC, dilakukan oleh Dubey dkk. Studi tersebut melaporkan bahwa training DistilBERT sekitar 1,74 kali lebih cepat dengan performa yang masih bersaing [8], [13]. Akan tetapi, kedua model digabungkan dengan ringkasan konteks dari BART dan embedding metadata, sehingga sulit diketahui seberapa besar peran model itu sendiri. Eksperimennya juga hanya memakai subset 7.370 sampel [8], sementara tahap prapemrosesannya membuang huruf kapital dan tanda baca [13]. Padahal, kedua hal tersebut bisa menjadi petunjuk adanya sarkasme. Pada [13], selisih performa kedua model bahkan tidak signifikan menurut paired t-test ($p = 0{,}064$). Zhang dkk. [14] menggunakan SARC dengan skala yang lebih besar, tetapi tidak memisahkan data uji dari data validasi. Di sisi lain, cara memasukkan parent comment ke dalam model dan pembekuan layer, yang dapat menjadi pilihan penghematan biaya selain distilasi, masih jarang dibahas bersama biaya komputasinya dalam konteks deteksi sarkasme.

Berdasarkan uraian tersebut, penelitian ini membandingkan performa dan efisiensi komputasi RoBERTa dan DistilBERT pada sekitar satu juta pasangan comment SARC tanpa tambahan komponen lain. Trade-off di antara keduanya kemudian dianalisis untuk menentukan kondisi yang paling cocok bagi masing-masing model. Tujuan ini diuraikan ke dalam tiga pertanyaan penelitian berikut.

1) Apakah jumlah layer yang dibekukan memiliki pengaruh terhadap performa klasifikasi sarkasme?
2) Apakah pemanfaatan parent comment sebagai input memiliki pengaruh terhadap performa klasifikasi sarkasme?
3) Strategi fusion seperti apa yang mampu memberikan performa terbaik dalam klasifikasi sarkasme?

Ketiga pertanyaan dijawab untuk kedua model dengan mempertimbangkan biaya komputasi berupa waktu training, latensi inferensi, memori GPU, dan jumlah parameter. Adapun kontribusi penelitian ini adalah (i) perbandingan kedua model dengan prapemrosesan ringan, konfigurasi yang dikunci sebelum data uji dibuka, tiga seed, serta uji statistik dengan koreksi Holm; (ii) pengukuran biaya komputasi yang disandingkan dengan performa untuk tiga konfigurasi input dan beberapa tingkat pembekuan layer; dan (iii) analisis jenis comment yang paling terbantu oleh parent comment.

II. Metode

A. Dataset dan Prapemrosesan

Penelitian ini menggunakan SARC [5] versi seimbang yang dirilis di Kaggle. Versi yang sama juga digunakan pada [13] dan [14]. Data tersebut memuat 1.010.826 pasangan comment Reddit beserta parent comment yang dibalasnya. Labelnya tidak berasal dari anotator, melainkan dari penanda "/s" yang ditambahkan sendiri oleh penulis comment, dan penanda ini sudah dihapus dari teks ketika korpus disusun [5].

Tahap prapemrosesan sengaja dibuat sederhana. Pada penelitian sebelumnya, teks diubah ke huruf kecil, tanda baca atau karakter khusus dihapus, lalu dilakukan lematisasi [13], [14]. Langkah-langkah tersebut tidak diterapkan di sini, sebab huruf kapital, tanda baca, dan emotikon seperti ";)" berpotensi menjadi penanda sarkasme. Pembersihan hanya meliputi dekode entitas HTML, penggantian tautan Markdown dengan teksnya, penghapusan URL dan tag HTML, serta perapian spasi. Dengan cara ini, hanya 2.942 comment (0,29%) yang mengalami perubahan.

Jumlah baris yang dibuang pada tiap tahap ditampilkan pada Tabel I. Pencarian duplikat dan label yang saling bertentangan memakai kunci yang dinormalisasi (huruf kecil dan tanpa tanda baca), tetapi teks yang masuk ke model tetap teks aslinya. Pada tahap terakhir, artefak sisa penghapusan penanda "/s" dibuang. Artefak ini berupa comment yang hanya berisi potongan kalimat, contohnya "You forgot the". Potongan tersebut dicari dengan pola yang panjangnya maksimal delapan kata. Dari 8.599 baris yang cocok, 8.580 di antaranya berlabel sarkas, sehingga seluruh baris itu dihapus agar model tidak belajar dari jalan pintas tersebut. Setelah penyaringan, tersisa 1.000.864 pasangan dengan proporsi sarkas 49,59%.

Tabel I
Penyaringan Baris dan Pembagian Data

Tahap penyaringan	Dibuang	Sisa
Data mentah	–	1.010.826
Comment kosong	55	1.010.771
Kosong setelah dibersihkan	9	1.010.762
Label bertentangan	142	1.010.620
Pasangan duplikat	1.157	1.009.463
Potongan "/s"	8.599	1.000.864
Bagian data	**Pasangan**	**Sarkas (%)**
Latih	799.459	49,66
Validasi	100.276	49,38
Uji	101.129	49,27

Pembagian data latih, validasi, dan uji dilakukan dengan seed 42. Data dibagi berdasarkan kelompok comment, bukan per baris, sehingga comment dengan kunci yang sama selalu masuk ke bagian yang sama. Cara ini diperlukan karena balasan pendek seperti "Source?" dan "Yes." muncul ratusan kali dalam data. Hasil pembagian mendekati rasio 80/10/10, dan tidak ada comment maupun pasangan yang muncul di lebih dari satu bagian.

B. Model dan Konfigurasi Input

RoBERTa-base [9] terdiri atas 12 layer Transformer dengan ukuran hidden 768 dan total 124,6 juta parameter. DistilBERT [11] merupakan hasil distilasi BERT dengan ukuran hidden yang sama, tetapi hanya memiliki enam layer dan 65,8 juta parameter. Versi cased dipilih untuk DistilBERT supaya kedua model sama-sama dapat membedakan huruf kapital. Untuk mengamati pengaruh parent comment dan strategi fusion, tiga konfigurasi input dibandingkan sebagai berikut.

Comment saja. Model hanya menerima teks balasan. Konfigurasi ini digunakan sebagai baseline.

Early fusion. Parent dan comment disatukan menjadi satu input menggunakan format pasangan kalimat dari tokenizer, dengan parent diletakkan di depan. Cara ini serupa dengan penggabungan konteks dan respons pada [7]. Dengan susunan tersebut, setiap token comment dapat memperhatikan semua token parent mulai dari layer pertama. Panjang input dibatasi 256 token. Jika melebihi batas, bagian akhir parent dipotong, dan hal ini terjadi pada 0,85% pasangan latih untuk RoBERTa serta 0,99% untuk DistilBERT. Comment yang lebih panjang dari 256 token juga dipotong, tetapi jumlahnya hanya 52–54 comment latih (kurang dari 0,01%).

Late fusion. Parent dan comment di-encode secara terpisah dengan encoder yang sama. Hidden state akhir pada token pertama comment (h_x) dan parent (h_y) kemudian digabungkan menjadi

$$u = [\, h_x;\ h_y;\ |h_x - h_y|;\ h_x \odot h_y \,], \tag{1}$$

dengan $[\cdot\,;\cdot]$ menyatakan penggabungan vektor dan $\odot$ perkalian per elemen. Vektor u pada (1) diteruskan ke head klasifikasi. Struktur head ini mengikuti head bawaan masing-masing model, hanya saja ukuran inputnya empat kali lebih besar. Aturan pemotongan teks sama dengan early fusion. Akibat rancangan ini, encoder harus dijalankan dua kali untuk

Tabel II
PENGATURAN TRAINING

Pengaturan	Nilai
Panjang input maksimum	256 token
Ukuran batch	32 (evaluasi: 128)
Epoch	maks. 3, terbaik menurut macro-F1 validasi
Loss	cross-entropy
Optimizer	AdamW, weight decay 0,01
Jadwal learning rate	warm-up linear 10%, lalu turun linear
Gradient clipping	1,0
Dropout classifier	0,1 (RoBERTa), 0,2 (DistilBERT)
Presisi	BF16 mixed precision
Grid learning rate (S1)	$\{1, 2, 3, 5\} \times 10^{-5}$
Seed	42 (S1); 42, 43, 44 (run final)
Learning rate terpilih (RoBERTa / DistilBERT)	
Comment saja	1×10^{-5} / 3×10^{-5}
Early fusion	2×10^{-5} / 1×10^{-5}
Late fusion	1×10^{-5} / 1×10^{-5}

setiap contoh, dan token comment tidak dapat memperhatikan token parent secara langsung.

C. Pembekuan Layer

Pembekuan layer termasuk fine-tuning selektif karena hanya sebagian parameter yang dilatih [15], dan dapat menghemat memori GPU dengan penurunan akurasi yang kecil [16]. Pada eksperimen ini, embedding layer dan sejumlah layer paling bawah dibekukan, sehingga yang dilatih hanya layer atas dan head. Pengujian ini dilakukan pada early fusion dengan jumlah layer beku 0, 6, 9, dan 12 dari 12 layer RoBERTa, serta 0, 3, dan 6 dari 6 layer DistilBERT. Model yang dibekukan sebagian dilatih dengan tiga seed menggunakan learning rate terbaik dari fine-tuning penuh. Untuk model yang seluruh layernya dibekukan, learning rate 10^{-4} dan 10^{-3} dicoba pada seed 42, kemudian dipilih yang terbaik berdasarkan data validasi. Perlu dicatat bahwa pembekuan hanya mengurangi biaya training, karena seluruh layer tetap dijalankan pada saat inferensi.

D. Pengaturan Eksperimen

Pengaturan training dirangkum pada Tabel II. Bias dan parameter LayerNorm tidak dikenai weight decay, dan padding pada setiap batch hanya dilakukan sampai panjang urutan terpanjang di batch tersebut. Epoch yang dipakai adalah epoch dengan macro-F1 validasi tertinggi. Learning rate ditentukan melalui pencarian grid karena RoBERTa diketahui sensitif terhadap pengaturan training [4]. Grid tersebut memuat nilai 2×10^{-5} dan 3×10^{-5} yang digunakan pada [13], [12].

Secara keseluruhan, 60 run dijalankan dalam tiga skenario, yaitu pencarian learning rate dengan seed 42 (S1, 24 run), pembekuan layer (S2, 16 run), dan pengulangan dengan seed 43 dan 44 (S3, 20 run). Dari jumlah tersebut, 29 run dinilai pada data uji, terdiri atas 6 run S1, 11 run S2, dan 12 run S3. Run sisanya berisi learning rate yang kalah pada data validasi atau masih menggunakan learning rate dari percobaan awal sebelum pencarian learning rate selesai (11 run). Seluruh run dijalankan pada satu GPU NVIDIA GeForce RTX 5070 Ti 16 GB. Waktu training dihitung per epoch tanpa menyertakan validasi, sedangkan memori yang dicatat adalah memori GPU puncak selama training. Latensi diukur sebagai waktu forward pass dengan input yang sudah berada di GPU. Pengukuran ini memakai 1.000 contoh validasi pada ukuran batch 1 dan 32, dengan sepuluh batch pertama sebagai pemanasan yang tidak dihitung, lalu hasilnya dinyatakan per contoh. Angka efisiensi dirata-ratakan dari run final yang sama dengan run yang dinilai pada data uji.

E. Evaluasi dan Uji Statistik

Sebuah comment diprediksi sarkas jika probabilitasnya bernilai 0,5 atau lebih. Metrik yang dilaporkan meliputi accuracy, precision, recall, dan F1 untuk kelas sarkas, ditambah macro-F1 sebagai metrik utama. Pemilihan epoch dan learning rate hanya menggunakan data validasi. Prediksi pada data uji disimpan tanpa dihitung skornya, dan daftar 29 run final dicatat dalam file manifest yang di-commit ke repositori proyek pada 16 Oktober 2026, sebelum skor data uji dihitung. Tiga seed dipakai karena performa jaringan saraf dapat berubah akibat seed acak [17]. Skor disajikan sebagai rata-rata dan simpangan baku dari seed 42, 43, dan 44, kecuali untuk model yang seluruh layernya dibekukan karena hanya memiliki satu run.

Semua perbandingan diuji dengan hipotesis satu arah [18]. Sebagai contoh, pada perbandingan parent comment, H_0 menyatakan bahwa macro-F1 dengan parent tidak lebih tinggi daripada tanpa parent, sedangkan H_1 menyatakan hal sebaliknya. Data yang diuji adalah macro-F1 data uji per seed, yang dipasangkan berdasarkan seed dan model. Perbandingan dua konfigurasi diuji dengan paired t-test satu arah. Wilcoxon signed-rank satu arah hanya ditambahkan pada perbandingan gabungan, karena dengan tiga pasangan nilai p terkecil yang dapat dicapai Wilcoxon adalah 0,125. Perbandingan tiga perlakuan atau lebih, yakni ketiga input, ketiga seed, dan keempat learning rate, diuji dengan Friedman test. Besar efek dinyatakan sebagai rata-rata selisih beserta selang kepercayaan 95% dua arah (CI 95%) untuk uji dua konfigurasi, dan sebagai Kendall's W untuk Friedman test. Normalitas selisih pada perbandingan gabungan diperiksa dengan uji Shapiro-Wilk. Mengingat jumlah uji yang cukup banyak, nilai p dikoreksi dengan metode Holm di dalam setiap kelompok pertanyaan, dengan taraf signifikansi 0,05. Biaya komputasi diuji dengan prosedur yang sama. Sebagai uji pendukung, pasangan run juga dibandingkan pada tingkat contoh data uji menggunakan McNemar's test dengan koreksi Holm. Selain itu, analisis eksploratif dilakukan untuk membandingkan early fusion dengan comment saja pada beberapa subkelompok data uji, yaitu berdasarkan panjang comment, comment yang muncul dengan label berbeda, dan tingkat keyakinan model comment saja RoBERTa. Model dianggap ragu jika rata-rata probabilitasnya berada pada rentang 0,4–0,6.

III. HASIL

A. Performa dan Efisiensi Kedua Model

Skor data uji dan biaya komputasi untuk enam konfigurasi utama disajikan pada Tabel III. Nilai tertinggi di semua metrik diperoleh RoBERTa dengan early fusion, dengan macro-F1 sebesar 79,62%. Pada ketiga input, RoBERTa mengungguli DistilBERT dengan selisih 1,65–2,07 poin. Keunggulan

tersebut muncul pada seluruh sembilan pasangan seed dan input. Selisih gabungannya sebesar 1,81 poin (CI 95% 1,65–1,97) dan tetap signifikan setelah koreksi Holm (Tabel IV). Hasilnya juga stabil. Simpangan baku accuracy dan macro-F1 tidak lebih dari 0,09 poin, perbedaan macro-F1 antara data validasi dan data uji hanya berkisar $-0{,}07$ hingga 0,26 poin, dan Friedman test tidak menemukan perbedaan antarseed ($p = 0{,}311$). Berbeda dengan seed, learning rate memberikan pengaruh yang signifikan ($p_{\text{Holm}} = 0{,}004$). Learning rate 5×10^{-5} selalu menghasilkan macro-F1 validasi paling rendah, dan penurunan terbesarnya terjadi pada RoBERTa.

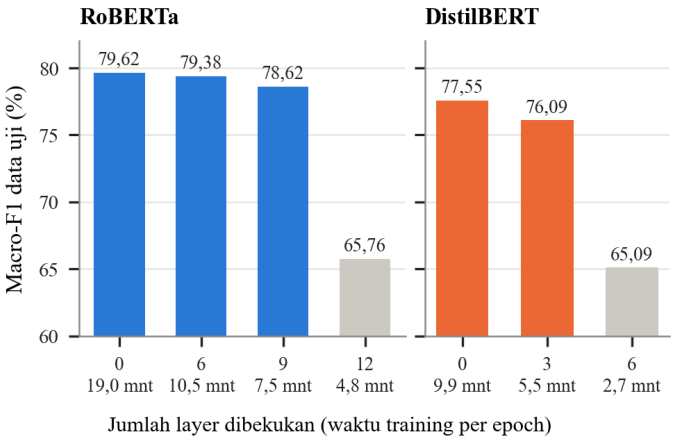
Dilihat dari sisi efisiensi, jumlah parameter RoBERTa 1,9 kali lebih banyak, dan biaya komputasinya kira-kira dua kali DistilBERT pada semua input. Waktu training RoBERTa 1,92–1,94 kali lebih lama, kebutuhan memorinya 1,93–1,96 kali lebih besar, dan latensinya pada batch 1 lebih tinggi 1,99–2,09 kali. Pola ini muncul secara konsisten pada kesembilan pasangan seed dan input (Wilcoxon, $p = 0{,}002$ untuk ketiga ukuran) dan tetap signifikan setelah koreksi Holm.

B. Pengaruh Jumlah Layer yang Dibekukan

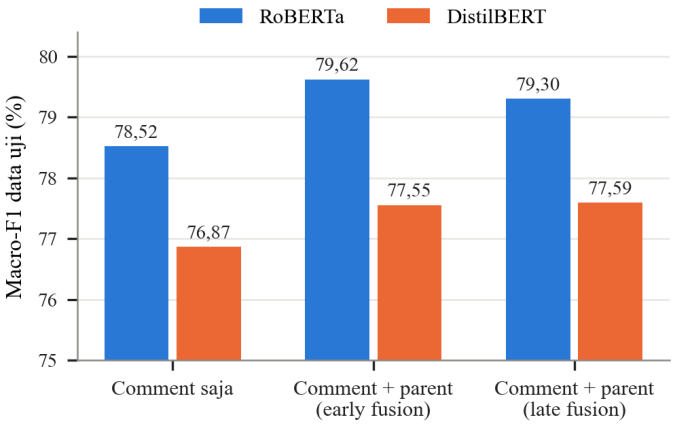
Gambar 1 menampilkan macro-F1 dan waktu training untuk setiap jumlah layer yang dibekukan. Ketika 6 dari 12 layer RoBERTa dibekukan, macro-F1 hanya turun dari 79,62% menjadi 79,38%. Penurunan 0,24 poin ini terjadi di ketiga seed dan signifikan menurut paired t-test satu arah ($p_{\text{Holm}} = 0{,}028$), dengan batas bawah CI 95% satu arah sebesar 0,07 poin. Meski demikian, CI 95% dua arah ($-0{,}02$–0,49) masih sedikit melewati nol dan McNemar tidak menganggapnya signifikan, sehingga penurunan ini dapat dikatakan kecil. Di sisi biaya, waktu training berkurang dari 19,03 menjadi 10,51 menit per epoch, dan memori turun dari 5,11 menjadi 2,70 GB. Saat 9 layer dibekukan, RoBERTa masih mencapai 78,62%. Angka ini 1,07 poin lebih tinggi daripada DistilBERT penuh, padahal waktu training-nya lebih singkat (7,49 berbanding 9,93 menit) dan memorinya lebih kecil (1,67 berbanding 2,64 GB). DistilBERT ternyata lebih sensitif terhadap pembekuan, karena pembekuan 3 dari 6 layer saja sudah menurunkan macro-F1 sebesar 1,47 poin. Apabila seluruh layer dibekukan, macro-F1 kedua model jatuh ke kisaran 65%. Latensi relatif tidak berubah, yaitu 7,80–8,41 ms pada RoBERTa dan 3,91–4,23 ms pada DistilBERT, dan penurunan latensi akibat pembekuan tidak signifikan setelah koreksi Holm ($p_{\text{Holm}} = 0{,}079$).

C. Pengaruh Parent Comment

Hasil Friedman test menunjukkan adanya perbedaan macro-F1 di antara ketiga input ($p = 0{,}009$, Kendall's $W = 0{,}78$). Seperti terlihat pada Gambar 2, penambahan parent menaikkan macro-F1 pada kedua model. Dengan early fusion, kenaikannya mencapai 1,10 poin pada RoBERTa dan 0,69 poin pada DistilBERT, sementara late fusion memberikan kenaikan 0,78 dan 0,72 poin. Keempat kenaikan ini signifikan, baik menurut paired t-test setelah koreksi Holm maupun menurut McNemar. Tambahan biaya dari early fusion tergolong kecil. Waktu training hanya bertambah 1,15–1,16 kali, sedangkan latensi batch 1 dan memori hampir tidak berubah. Hanya



Gambar 1. Macro-F1 data uji menurut jumlah layer yang dibekukan pada early fusion. Angka di bawah sumbu menunjukkan waktu training per epoch. Batang abu-abu adalah model yang seluruh layernya dibekukan (satu seed); batang lain adalah rata-rata tiga seed.



Gambar 2. Macro-F1 data uji untuk setiap model dan konfigurasi input (rata-rata tiga seed). Sumbu vertikal dimulai dari 75% agar selisih antarkonfigurasi terlihat.

latensi per contoh pada batch 32 yang naik menjadi kurang lebih dua kali lipat.

Manfaat parent ternyata tidak merata pada semua comment. Pada 10.737 comment yang membuat model comment saja RoBERTa ragu, early fusion menaikkan macro-F1 RoBERTa hingga 8,18 poin, sedangkan pada comment yang sudah diprediksi dengan yakin kenaikannya hanya 0,25 poin. Kenaikan pada comment pendek 1–3 kata (2,59 poin) juga lebih besar dibandingkan comment yang lebih dari 10 kata (0,71 poin). Pada 5.886 comment (593 kalimat unik) yang muncul dengan label berbeda, kenaikannya mencapai 2,73 poin. Walaupun begitu, parent tidak selalu membantu. Pada RoBERTa, parent memperbaiki rata-rata 6.236 prediksi per seed, tetapi juga membuat 5.119 prediksi lain menjadi salah.

D. Strategi Fusion Terbaik

Pada RoBERTa, early fusion menghasilkan macro-F1 tertinggi dan unggul 0,32 poin dibanding late fusion (CI 95% 0,15–0,49, $p_{\text{Holm}} = 0{,}023$). Hasil ini juga signifikan menurut

Tabel III
SKOR DATA UJI DAN BIAYA KOMPUTASI KONFIGURASI UTAMA

Input	Model	Skor data uji (%) Accuracy	Precision	Recall	F1	Macro-F1	Training (menit/epoch)	Latensi (ms) bs 1	bs 32	Memori (GB)
Comment saja	DistilBERT	76,88 ± 0,08	76,94 ± 0,65	75,80 ± 1,17	76,36 ± 0,29	76,87 ± 0,08	8,56	4,19	0,15	2,63
	RoBERTa	78,53 ± 0,07	78,33 ± 0,36	77,99 ± 0,46	78,16 ± 0,05	78,52 ± 0,06	16,61	8,42	0,31	5,09
Early fusion	DistilBERT	77,58 ± 0,06	78,14 ± 1,11	75,70 ± 2,03	76,88 ± 0,53	77,55 ± 0,09	9,93	4,23	0,32	2,64
	RoBERTa	**79,63** ± 0,05	**79,37** ± 1,31	**79,32** ± 2,22	**79,32** ± 0,48	**79,62** ± 0,06	19,03	8,41	0,61	5,11
Late fusion	DistilBERT	77,60 ± 0,02	77,62 ± 0,07	76,61 ± 0,07	77,12 ± 0,02	77,59 ± 0,02	14,92	7,20	0,42	4,29
	RoBERTa	79,30 ± 0,02	78,82 ± 0,21	79,29 ± 0,39	79,06 ± 0,09	79,30 ± 0,02	28,82	15,06	0,83	8,38

Early dan late fusion memakai comment + parent. Skor adalah rata-rata ± simpangan baku dari seed 42, 43, dan 44, dan biaya dirata-ratakan dari run yang sama. Precision, recall, dan F1 dihitung untuk kelas sarkas. Latensi pada ukuran batch (bs) 32 dinyatakan per contoh.

Tabel IV
HASIL UJI HIPOTESIS PADA DATA UJI

H_1	n	Δ	CI 95%	p_{Holm}	p_W	McN.
Performa: RoBERTa > DistilBERT						
Gabungan 3 input	9	1,81	1,65–1,97	<0,001	0,002	ya
Pembekuan layer: fine-tuning penuh > dibekukan sebagian						
RoBERTa, 6 layer	3	0,24	−0,02–0,49	0,028	–	tidak
RoBERTa, 9 layer	3	1,00	0,81–1,18	0,002	–	–
DistilBERT, 3 layer	3	1,47	1,28–1,66	0,002	–	–
Gabungan	9	0,90	0,48–1,32	0,002	0,002	–
Input: perbedaan ketiga input (Friedman)						
Comment, early, late	6	$W = 0{,}78$		0,009	–	–
Parent comment: comment + parent > comment saja						
Early, RoBERTa	3	1,10	0,83–1,37	0,004	–	ya
Early, DistilBERT	3	0,69	0,65–0,72	<0,001	–	ya
Late, RoBERTa	3	0,78	0,60–0,96	0,004	–	ya
Late, DistilBERT	3	0,72	0,53–0,92	0,004	–	ya
Early, gabungan	6	0,89	0,64–1,14	<0,001	0,016	–
Late, gabungan	6	0,75	0,67–0,83	<0,001	0,016	–
Strategi fusion: early fusion > late fusion						
RoBERTa	3	0,32	0,15–0,49	0,023	–	ya
DistilBERT	3	−0,04	−0,26–0,19	0,725	–	tidak
Gabungan	6	0,14	−0,08–0,36	0,158	0,109	–
Biaya: RoBERTa > DistilBERT (gabungan 3 input)						
Training (menit/epoch)	9	10,35	8,27–12,43	<0,001	0,002	–
Latensi bs 1 (ms)	9	5,42	4,01–6,82	<0,001	0,002	–
Memori (GB)	9	3,01	2,38–3,64	<0,001	0,002	–
Pendukung (Friedman)						
Ketiga seed	6	$W = 0{,}19$		0,311	–	–
Learning rate (validasi)	6	$W = 0{,}74$		0,004	–	–

n: jumlah pasangan atau blok; Δ: rata-rata selisih (poin macro-F1, atau satuan biaya); CI 95%: dua arah, sehingga dapat sedikit mencakup nol walaupun uji satu arah signifikan; p_{Holm}: p paired t-test atau Friedman setelah koreksi Holm per kelompok pertanyaan; p_W: Wilcoxon; McN.: signifikan menurut McNemar dan koreksi Holm pada ketiga seed (–: tidak diuji).

McNemar. Pada DistilBERT, kedua strategi memberikan hasil yang setara (77,55% dan 77,59%). Jika kedua model digabung, keunggulan early fusion belum signifikan ($p_{\text{Holm}} = 0{,}158$, CI 95% $-0{,}08$–$0{,}36$). Dari segi biaya, late fusion merupakan konfigurasi paling mahal, dengan waktu training sekitar 1,5 kali, memori 1,62–1,64 kali, dan latensi batch 1 sebesar 1,70–1,79 kali dibanding early fusion.

IV. PEMBAHASAN

A. Trade-off antara RoBERTa dan DistilBERT

Hasil pengujian memberikan bukti statistik bahwa RoBERTa lebih akurat. Namun, keunggulan tersebut hanya 1,65–2,07 poin, sementara biayanya mencapai sekitar dua kali DistilBERT. Dengan kata lain, DistilBERT dapat mempertahankan 97–98% macro-F1 RoBERTa hanya dengan kira-kira setengah sumber daya. Rasio biaya ini hampir sama pada ketiga input, sehingga kemungkinan besar ditentukan oleh ukuran model. RoBERTa lebih cocok digunakan jika akurasi menjadi prioritas dan sumber daya tersedia, misalnya pada analisis offline. Sebaliknya, DistilBERT lebih cocok jika latensi dan memori terbatas, seperti pada alat moderasi yang harus memproses comment secara terus-menerus.

B. Pembekuan Layer dan Distilasi

Hasil uji mendukung adanya pengaruh jumlah layer yang dibekukan terhadap performa, meskipun pengaruhnya tidak linear. Pembekuan separuh layer RoBERTa hanya mengurangi macro-F1 sebesar 0,24 poin, padahal waktu training berkurang 45% dan memori berkurang 47%, sejalan dengan [16]. Penurunan yang jelas baru terlihat pada 9 layer dan menjadi sangat besar ketika semua layer dibekukan, sehingga representasi hasil pralatih tetap perlu di-fine-tune. Performa DistilBERT turun lebih cepat, yang kemungkinan disebabkan oleh jumlah layernya yang lebih sedikit. Selain itu, pembekuan dan distilasi menghemat bagian yang berbeda. Pembekuan hanya menghemat biaya training sehingga sesuai untuk model yang perlu sering dilatih ulang, sedangkan DistilBERT menghemat biaya inferensi karena latensinya kira-kira setengah dari RoBERTa.

C. Peran Parent Comment

Hasil uji memberikan bukti statistik bahwa parent comment meningkatkan performa kedua model, walaupun rata-rata kenaikannya hanya sekitar satu poin. Kenaikan yang kecil ini masuk akal, sebab sebagian besar comment sudah bisa dipahami dari isinya sendiri. Peran parent baru terasa ketika comment bersifat ambigu. Contohnya adalah balasan ";)" yang muncul 68 kali di data uji, dan hanya enam di antaranya yang sarkas. Sebagai balasan untuk "Sarcasm doesn't translate well through text. Haha", comment ini berlabel sarkas, sedangkan sebagai balasan untuk "What is your Guilty Pleasure?", comment yang sama tidak sarkas. Tanpa parent, model pasti memberikan prediksi yang sama untuk keduanya. Kenaikan yang diperoleh di sini jauh lebih kecil daripada laporan Dubey dkk. (7,1 poin [13] dan 6,8 poin [8]) yang menggunakan subset 7.370 sampel dengan tanda baca dan huruf kapital dihapus. Model comment saja tanpa tanda baca mungkin lebih bergantung pada parent, tetapi dugaan ini belum diuji.

D. Early Fusion dan Late Fusion

Early fusion dipilih sebagai strategi terbaik karena terdapat bukti statistik bahwa strategi ini lebih akurat pada RoBERTa, tidak berbeda nyata pada DistilBERT, dan biayanya jauh lebih rendah. Pada early fusion, token comment dapat memperhatikan kata tertentu di parent pada setiap layer, sedangkan pada late fusion kedua teks diringkas dulu menjadi satu vektor dan baru bertemu di head klasifikasi. Karena makna sarkasme sering ditentukan oleh frasa tertentu di parent, pendekatan late fusion tampaknya kurang menguntungkan. Late fusion mungkin masih berguna bila satu parent dibalas banyak comment karena vektor parent cukup dihitung sekali, tetapi hal ini tidak diuji.

E. Perbandingan dengan Penelitian Lain dan Keterbatasan

Beberapa penelitian melaporkan skor yang lebih tinggi, misalnya F1 95,6% pada [13] dan 0,917 pada [14]. Namun, ukuran data, prapemrosesan, dan protokol evaluasinya berbeda. Potongan "/s" (Bagian II-A) mungkin juga berpengaruh, karena hampir semuanya berlabel sarkas dan tidak ada laporan yang dirujuk yang menyebutkan apakah potongan itu dibuang. Rasio biayanya justru sejalan, karena waktu training RoBERTa pada SARC di [13] 1,76 kali DistilBERT (8,1 dan 4,6 jam), sedangkan di sini 1,92–1,94 kali.

Jawaban ketiga pertanyaan penelitian hanya berlaku untuk dataset dan pengaturan yang dipakai, dengan beberapa keterbatasan. Pertama, training dibatasi tiga epoch, padahal 24 dari 29 run final mencapai skor validasi terbaik pada epoch terakhir. Kedua, hanya satu dataset yang digunakan, dan labelnya berasal dari penanda "/s", sehingga comment sarkas yang tidak diberi penanda tercatat sebagai bukan sarkas [5]. Split uji resmi SARC juga tidak dapat dipakai karena teksnya tidak tersedia. Ketiga, model yang dibekukan memakai learning rate dari fine-tuning penuh, model yang seluruh layernya dibekukan hanya dijalankan dengan satu seed, dan setiap uji per konfigurasi hanya memiliki tiga pasangan. Terakhir, large language model tidak disertakan dan efisiensi hanya diukur pada satu GPU.

V. Kesimpulan

Penelitian ini mengkaji trade-off antara performa dan efisiensi komputasi RoBERTa dan DistilBERT untuk deteksi sarkasme pada SARC. RoBERTa terbukti lebih akurat secara statistik, tetapi keunggulannya hanya sekitar dua poin macro-F1, sedangkan biaya komputasinya kira-kira dua kali DistilBERT. Jumlah layer yang dibekukan memengaruhi performa, namun setengah layer RoBERTa masih dapat dibekukan dengan penurunan yang sangat kecil untuk menghemat biaya training. Penambahan parent comment meningkatkan performa kedua model, dan early fusion menjadi strategi terbaik karena paling akurat pada RoBERTa serta lebih hemat dibanding late fusion. Oleh sebab itu, RoBERTa dengan early fusion disarankan bila akurasi menjadi prioritas, sedangkan DistilBERT dengan early fusion cocok bila latensi dan memori terbatas. Penelitian selanjutnya dapat memperpanjang training, mencari learning rate khusus untuk model yang dibekukan, menguji dataset lain, dan membandingkan hasilnya dengan large language model.

Daftar Pustaka

[1] O. Prakash, "Sarcasm detection for sentiment analysis using deep learning enhancement," *Procedia Computer Science*, vol. 258, pp. 203–212, 2025.

[2] R. Dhumpati, A. Sasi, S. J. Basha, S. Vadhri, P. Saroja, S. Alluri, and R. Vatambeti, "Enhancing sarcasm detection in sentiment analysis for cyberspace safety using advanced deep learning techniques," *Scientific Reports*, vol. 15, p. 22681, 2025.

[3] V. Grover and H. Banati, "An emoji centric approach to sarcasm detection in online discourse," *Scientific Reports*, vol. 16, p. 3891, 2026.

[4] R. Jiménez Castro, J. P. Sánchez-Solís, V. García Jiménez, G. Rivera Zárate, and R. Florencia Juárez, "A comparative study of bert-based models for sarcasm detection in social media texts," *International Journal of Combinatorial Optimization Problems and Informatics*, vol. 17, no. 2, pp. 378–390, 2026.

[5] M. Khodak, N. Saunshi, and K. Vodrahalli, "A large self-annotated corpus for sarcasm," in *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*. Miyazaki, Japan: European Language Resources Association (ELRA), 2018.

[6] S. Hao, J. Yao, C. Shi, Y. Zhou, S. Xu, D. Li, and Y. Cheng, "Enhanced semantic representation learning for sarcasm detection by integrating context-aware attention and fusion network," *Entropy*, vol. 25, no. 6, p. 878, 2023.

[7] T. Shangipour Ataei, S. Javdan, and B. Minaei-Bidgoli, "Applying transformers and aspect-based sentiment analysis approaches on sarcasm detection," in *Proceedings of the Second Workshop on Figurative Language Processing*, 2020, pp. 67–71.

[8] P. Dubey, P. Dubey, and P. N. Bokoro, "Unpacking sarcasm: A contextual and transformer-based approach for improved detection," *Computers*, vol. 14, no. 3, p. 95, 2025.

[9] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "RoBERTa: A robustly optimized BERT pretraining approach," arXiv:1907.11692, 2019.

[10] M. Treviso, J.-U. Lee, T. Ji, B. van Aken, Q. Cao, M. R. Ciosici, M. Hassid, K. Heafield, S. Hooker, C. Raffel, P. H. Martins, A. F. T. Martins, J. Z. Forde, P. Milder, E. Simpson, N. Slonim, J. Dodge, E. Strubell, N. Balasubramanian, L. Derczynski, I. Gurevych, and R. Schwartz, "Efficient methods for natural language processing: A survey," *Transactions of the Association for Computational Linguistics*, vol. 11, pp. 826–860, 2023.

[11] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter," arXiv:1910.01108, 2019.

[12] M. A. Ullah, R. Sultana, S. H. Chowdhury, and F. A. Laila, "Advanced sarcasm detection using transformer-based models: Analyzing variations in formal and informal languages," *Applied Computational Intelligence and Soft Computing*, vol. 2026, p. 8761185, 2026.

[13] P. Dubey, A. Mishra, A. Singh, Murtuza, A. Chanchlani, and P. Dubey, "Efficient transformer architecture for sarcasm detection: A study on compression and performance," *Bulletin of Electrical Engineering and Informatics*, vol. 15, no. 1, pp. 557–567, 2026.

[14] L. Zhang, M. Faseeh, S. S. A. Naqvi, L. Hu, and A. Ghani, "Enhancing sarcasm detection on social media: A comprehensive study using llms and bert with multi-headed attention on sarc," *PLoS ONE*, vol. 20, no. 11, p. e0334120, 2025.

[15] Z. Han, C. Gao, J. Liu, J. Zhang, and S. Q. Zhang, "Parameter-efficient fine-tuning for large models: A comprehensive survey," *Transactions on Machine Learning Research*, 2024.

[16] A. Ardakani, A. Haan, S. Tan, D. T. Popovici, A. Cheung, C. Iancu, and K. Sen, "SlimFit: Memory-efficient fine-tuning of transformer-based models using training dynamics," in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, 2024, pp. 6218–6236.

[17] D. Ulmer, C. Hardmeier, and J. Frellsen, "deep-significance: Easy and meaningful statistical significance testing in the age of neural networks," in *ML Evaluation Standards Workshop at the International Conference on Learning Representations (ICLR)*, 2022.

[18] R. Dror, L. Peled-Cohen, S. Shlomov, and R. Reichart, *Statistical Significance Testing for Natural Language Processing*, ser. Synthesis Lectures on Human Language Technologies. Cham, Switzerland: Springer, 2020.