Analisis Trade-off antara Akurasi dan Efisiensi Komputasi dalam Deteksi Sarkasme Menggunakan DistilBERT dan RoBERTa

Falah Razan Hibrizi
Fakultas Informatika
Universitas Telkom
Bandung, Indonesia
alamat email

Nama Pembimbing
Fakultas Informatika
Universitas Telkom
Bandung, Indonesia
alamat email

***Abstrak*—Sarkasme sering menyatakan maksud yang berlawanan dengan arti harfiahnya, sehingga sistem analisis sentimen kerap salah membacanya. Penelitian ini mengkaji trade-off antara performa dan efisiensi komputasi RoBERTa dan DistilBERT menggunakan 1.000.864 pasangan comment dan parent comment dari Self-Annotated Reddit Corpus (SARC). Perbandingan mencakup tiga konfigurasi input, yaitu comment saja, early fusion, dan late fusion, serta pembekuan sebagian layer. Konfigurasi final dipilih dari data validasi dan dikunci sebelum skor data uji dihitung. Setiap konfigurasi dijalankan dengan tiga seed dan diuji dengan paired t-test, Wilcoxon signed-rank test, dan Friedman test dengan koreksi Holm. Macro-F1 tertinggi sebesar 79,62% diperoleh RoBERTa dengan early fusion, dan RoBERTa unggul 1,65–2,07 poin dibanding DistilBERT. Meski begitu, DistilBERT mencapai 97–98% macro-F1 RoBERTa dengan waktu training, latensi, dan memori GPU sekitar setengahnya. Parent comment menaikkan macro-F1 sebesar 0,69–1,10 poin, terutama pada comment yang ambigu. Pada RoBERTa, early fusion lebih akurat dan jauh lebih hemat daripada late fusion. Pembekuan 6 dari 12 layer RoBERTa hanya mengurangi macro-F1 sebesar 0,24 poin dan memangkas waktu training sekitar 45%, tetapi latensi inferensi tidak turun. RoBERTa lebih tepat bila akurasi diutamakan, sedangkan DistilBERT lebih tepat bila latensi dan memori terbatas.**

***Kata Kunci*—DistilBERT, deteksi sarkasme, efisiensi komputasi, parent comment, pembekuan layer, RoBERTa**

I. Pendahuluan

Dalam sarkasme, penutur mengatakan sesuatu yang berlawanan dengan maksud sebenarnya, misalnya memakai pujian untuk mengejek. Kalimat semacam ini sulit ditangani sistem analisis sentimen karena kata yang terlihat positif ternyata bermaksud negatif [1]. Akibatnya, pemantauan opini publik dan moderasi konten dapat keliru, termasuk dalam deteksi perundungan siber di media sosial [2], [3].

Pada teks tertulis tidak ada nada suara maupun ekspresi wajah sebagai petunjuk [4]. Di Reddit, sifat sarkas sebuah balasan sering baru terlihat setelah pembaca mengetahui komentar yang dibalas, yang disebut parent comment. Self-Annotated Reddit Corpus (SARC) [5] menyediakan pasangan parent comment dan balasan dalam jumlah sangat besar. Konteks lain, seperti informasi pengguna dan topik forum, juga membantu model pada SARC [6], dan memasukkan parent comment ke model transformer dilaporkan dapat menaikkan performa [7], [8].

RoBERTa [9] merupakan pengembangan BERT dengan prosedur pralatih yang diperbaiki. Akurasinya umumnya tinggi, tetapi kebutuhan memori dan waktu komputasinya besar, padahal sumber daya komputasi terbatas [10]. DistilBERT [11] dihasilkan melalui distilasi pengetahuan sehingga jumlah layernya tinggal setengah dan inferensinya lebih cepat. Studi yang membandingkan varian BERT untuk deteksi sarkasme menunjukkan bahwa performa sangat bergantung pada pilihan model dan pengaturan training [4], [12].

Dubey dkk. membandingkan RoBERTa dan DistilBERT, termasuk pada SARC, dan melaporkan training DistilBERT sekitar 1,74 kali lebih cepat dengan performa yang bersaing [8], [13]. Akan tetapi, kedua model digabung dengan ringkasan konteks BART dan embedding metadata, eksperimennya hanya memakai subset 7.370 sampel [8], dan prapemrosesannya membuang huruf kapital serta tanda baca yang dapat menjadi petunjuk sarkasme [13]. Selisih kedua model pada [13] juga tidak signifikan ($p = 0{,}064$). Zhang dkk. [14] memakai SARC berskala lebih besar, tetapi tidak memisahkan data uji dari data validasi. Selain itu, cara memasukkan parent comment dan pembekuan layer masih jarang dibahas bersama biaya komputasinya.

Oleh karena itu, penelitian ini membandingkan performa dan efisiensi komputasi RoBERTa dan DistilBERT pada sekitar satu juta pasangan comment SARC tanpa komponen tambahan, lalu menganalisis trade-off keduanya melalui tiga pertanyaan penelitian berikut.

1) Apakah jumlah layer yang dibekukan memiliki pengaruh terhadap performa klasifikasi sarkasme?
2) Apakah pemanfaatan parent comment sebagai input memiliki pengaruh terhadap performa klasifikasi sarkasme?
3) Strategi fusion seperti apa yang mampu memberikan performa terbaik dalam klasifikasi sarkasme?

Setiap pertanyaan dijawab untuk kedua model dengan mempertimbangkan waktu training, latensi inferensi, memori GPU, dan jumlah parameter. Kontribusi penelitian ini adalah (i) perbandingan dengan prapemrosesan ringan, konfigurasi yang

Tabel I
PENYARINGAN BARIS DAN PEMBAGIAN DATA

Tahap penyaringan	Dibuang	Sisa
Data mentah	–	1.010.826
Comment kosong	55	1.010.771
Kosong setelah dibersihkan	9	1.010.762
Label bertentangan	142	1.010.620
Pasangan duplikat	1.157	1.009.463
Potongan "/s"	8.599	1.000.864
Bagian data	**Pasangan**	**Sarkas (%)**
Latih	799.459	49,66
Validasi	100.276	49,38
Uji	101.129	49,27

dikunci sebelum data uji dibuka, tiga seed, dan uji statistik dengan koreksi Holm; (ii) pengukuran biaya komputasi untuk tiga input dan beberapa tingkat pembekuan layer; dan (iii) analisis jenis comment yang paling terbantu oleh parent.

II. METODE

A. Dataset dan Prapemrosesan

Penelitian ini memakai SARC [5] versi seimbang dari Kaggle, sama dengan [13], [14], yang berisi 1.010.826 pasangan comment dan parent comment. Labelnya berasal dari penanda "/s" yang ditambahkan penulis comment, dan penanda ini sudah dihapus dari teks [5].

Berbeda dengan [13], [14] yang mengubah teks ke huruf kecil, menghapus tanda baca, dan melakukan lematisasi, prapemrosesan di sini dibuat ringan karena huruf kapital, tanda baca, dan emotikon seperti ";)" dapat menjadi penanda sarkasme. Pembersihan hanya meliputi dekode entitas HTML, penggantian tautan Markdown dengan teksnya, penghapusan URL dan tag HTML, serta perapian spasi, sehingga hanya 2.942 comment (0,29%) yang berubah.

Tahap penyaringan ditampilkan pada Tabel I. Duplikat dan label bertentangan dicari dengan kunci yang dinormalisasi (huruf kecil, tanpa tanda baca), tetapi model tetap menerima teks asli. Tahap terakhir membuang sisa penghapusan "/s" berupa potongan kalimat seperti "You forgot the", yang dicari dengan pola maksimal delapan kata. Dari 8.599 baris yang cocok, 8.580 berlabel sarkas, sehingga semuanya dihapus agar model tidak belajar dari jalan pintas ini. Hasilnya 1.000.864 pasangan dengan proporsi sarkas 49,59%.

Data dibagi dengan seed 42 berdasarkan kelompok comment, bukan per baris, karena balasan pendek seperti "Source?" muncul ratusan kali. Hasilnya mendekati rasio 80/10/10 tanpa comment maupun pasangan yang muncul di lebih dari satu bagian.

B. Model dan Konfigurasi Input

RoBERTa-base [9] memiliki 12 layer, ukuran hidden 768, dan 124,6 juta parameter, sedangkan DistilBERT [11] memiliki enam layer dan 65,8 juta parameter. Versi cased dipilih untuk DistilBERT agar kedua model dapat membedakan huruf kapital. Tiga konfigurasi input dibandingkan.

Comment saja. Model hanya menerima teks balasan sebagai baseline.

Tabel II
PENGATURAN TRAINING

Pengaturan	Nilai
Panjang input maksimum	256 token
Ukuran batch	32 (evaluasi: 128)
Epoch	maks. 3, terbaik menurut macro-F1 validasi
Optimizer	AdamW, weight decay 0,01
Jadwal learning rate	warm-up linear 10%, lalu turun linear
Gradient clipping	1,0
Dropout classifier	0,1 (RoBERTa), 0,2 (DistilBERT)
Presisi	BF16 mixed precision
Grid learning rate (S1)	$\{1, 2, 3, 5\} \times 10^{-5}$
Seed	42 (S1); 42, 43, 44 (run final)
Learning rate terpilih (RoBERTa / DistilBERT)	
Comment saja	1×10^{-5} / 3×10^{-5}
Early fusion	2×10^{-5} / 1×10^{-5}
Late fusion	1×10^{-5} / 1×10^{-5}

Early fusion. Parent dan comment disatukan dengan format pasangan kalimat tokenizer, dengan parent di depan, serupa dengan [7], sehingga token comment dapat memperhatikan semua token parent sejak layer pertama. Panjang input dibatasi 256 token dengan memotong akhir parent, yang terjadi pada 0,85% pasangan latih RoBERTa dan 0,99% DistilBERT. Comment yang melebihi 256 token hanya 52–54 (kurang dari 0,01%).

Late fusion. Parent dan comment di-encode terpisah dengan encoder yang sama. Hidden state akhir token pertama comment (h_x) dan parent (h_y) digabung menjadi

$$u = [\, h_x;\ h_y;\ |h_x - h_y|;\ h_x \odot h_y \,], \tag{1}$$

dengan $[\cdot\,;\cdot]$ penggabungan vektor dan $\odot$ perkalian per elemen. Vektor u diteruskan ke head klasifikasi bawaan model dengan ukuran input empat kali lebih besar. Akibatnya, encoder dijalankan dua kali per contoh dan token comment tidak dapat memperhatikan token parent secara langsung.

C. Pembekuan Layer

Pembekuan layer termasuk fine-tuning selektif karena hanya sebagian parameter yang dilatih [15], dan dapat menghemat memori GPU dengan penurunan akurasi kecil [16]. Embedding layer dan sejumlah layer terbawah dibekukan pada early fusion, yaitu 0, 6, 9, dan 12 dari 12 layer RoBERTa serta 0, 3, dan 6 dari 6 layer DistilBERT. Model yang dibekukan sebagian memakai learning rate terbaik dari fine-tuning penuh dengan tiga seed. Untuk model yang dibekukan seluruhnya, learning rate 10^{-4} dan 10^{-3} dicoba pada seed 42 dan dipilih yang terbaik di validasi. Pembekuan hanya mengurangi biaya training karena semua layer tetap dijalankan saat inferensi.

D. Pengaturan Eksperimen

Pengaturan training dirangkum pada Tabel II. Bias dan LayerNorm tidak dikenai weight decay, dan padding hanya sampai urutan terpanjang di setiap batch. Learning rate dipilih melalui pencarian grid karena RoBERTa sensitif terhadap pengaturan training [4], dan grid tersebut memuat nilai yang dipakai pada [13], [12].

Sebanyak 60 run dijalankan dalam tiga skenario: pencarian learning rate dengan seed 42 (S1, 24 run), pembekuan layer

(S2, 16 run), dan pengulangan seed 43 dan 44 (S3, 20 run). Sebanyak 29 run dinilai pada data uji (6 S1, 11 S2, 12 S3), sedangkan sisanya memakai learning rate yang kalah di validasi atau learning rate percobaan awal. Semua run memakai satu GPU NVIDIA GeForce RTX 5070 Ti 16 GB. Waktu training dihitung per epoch tanpa validasi, memori adalah memori GPU puncak selama training, dan latensi adalah waktu forward pass pada 1.000 contoh validasi dengan ukuran batch 1 dan 32, setelah sepuluh batch pemanasan, dinyatakan per contoh.

E. Evaluasi dan Uji Statistik

Comment diprediksi sarkas jika probabilitasnya minimal 0,5. Metrik yang dilaporkan adalah accuracy, precision, recall, dan F1 kelas sarkas, dengan macro-F1 sebagai metrik utama. Pemilihan epoch dan learning rate hanya memakai data validasi, dan daftar 29 run final di-commit ke repositori proyek pada 16 Oktober 2026 sebelum skor data uji dihitung. Tiga seed dipakai karena performa jaringan saraf dapat berubah akibat seed acak [17], dan skor disajikan sebagai rata-rata $\pm$ simpangan baku.

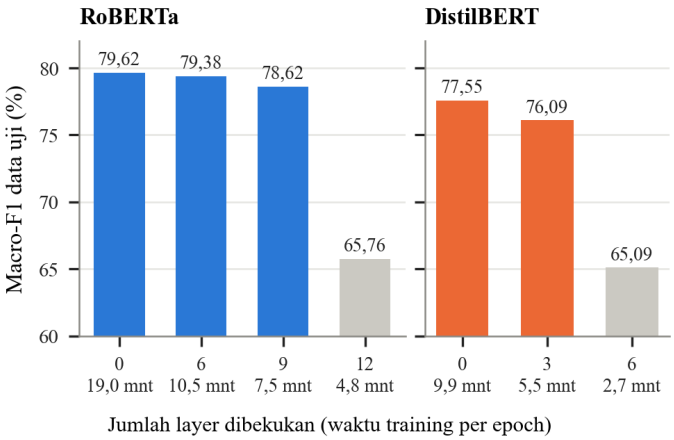
Semua perbandingan memakai hipotesis satu arah [18]; misalnya H_1 menyatakan macro-F1 dengan parent lebih tinggi daripada tanpa parent. Macro-F1 data uji per seed dipasangkan berdasarkan seed dan model, lalu diuji dengan paired t-test satu arah. Wilcoxon signed-rank hanya dipakai pada perbandingan gabungan, karena dengan tiga pasangan nilai p terkecilnya 0,125. Tiga perlakuan atau lebih (input, seed, learning rate) diuji dengan Friedman test. Besar efek dinyatakan sebagai rata-rata selisih dengan CI 95% dua arah atau Kendall's W, dan normalitas selisih gabungan diperiksa dengan Shapiro-Wilk. Nilai p dikoreksi dengan metode Holm per kelompok pertanyaan ($\alpha = 0{,}05$), termasuk untuk biaya komputasi. McNemar's test dengan koreksi Holm dipakai sebagai uji pendukung pada tingkat contoh. Analisis subkelompok juga dilakukan berdasarkan panjang comment, comment yang muncul dengan label berbeda, dan keyakinan model comment saja RoBERTa (ragu jika rata-rata probabilitasnya 0,4–0,6).

III. Hasil

A. Performa dan Efisiensi Kedua Model

Seperti terlihat pada Tabel III, nilai tertinggi di semua metrik diperoleh RoBERTa dengan early fusion (macro-F1 79,62%). RoBERTa mengungguli DistilBERT sebesar 1,65–2,07 poin pada ketiga input dan di kesembilan pasangan seed dan input, dengan selisih gabungan 1,81 poin (CI 95% 1,65–1,97) yang signifikan setelah koreksi Holm (Tabel IV). Hasilnya stabil: simpangan baku macro-F1 maksimal 0,09 poin, selisih validasi dan uji hanya $-0{,}07$ hingga 0,26 poin, dan Friedman test tidak menemukan perbedaan antarseed ($p = 0{,}311$, $W = 0{,}19$). Sebaliknya, learning rate berpengaruh signifikan ($p_{\text{Holm}} = 0{,}004$, $W = 0{,}74$), dan nilai 5×10^{-5} selalu menghasilkan macro-F1 validasi terendah, terutama pada RoBERTa.

Dari sisi efisiensi, parameter RoBERTa 1,9 kali lebih banyak dan biayanya sekitar dua kali DistilBERT: waktu training 1,92–1,94 kali, memori 1,93–1,96 kali, dan latensi batch 1 sebesar 1,99–2,09 kali. Pola ini konsisten di kesembilan pasangan dan signifikan setelah koreksi Holm.



Gambar 1. Macro-F1 data uji menurut jumlah layer yang dibekukan pada early fusion. Angka di bawah sumbu menunjukkan waktu training per epoch. Batang abu-abu adalah model yang seluruh layernya dibekukan (satu seed); batang lain adalah rata-rata tiga seed.

B. Pengaruh Jumlah Layer yang Dibekukan

Gambar 1 menunjukkan bahwa pembekuan 6 dari 12 layer RoBERTa hanya menurunkan macro-F1 dari 79,62% menjadi 79,38%. Penurunan 0,24 poin ini terjadi di ketiga seed dan signifikan menurut paired t-test ($p_{\text{Holm}} = 0{,}028$, batas bawah CI 95% satu arah 0,07), tetapi CI dua arahnya masih sedikit melewati nol dan McNemar tidak signifikan, sehingga penurunannya kecil. Sementara itu, waktu training turun dari 19,03 menjadi 10,51 menit per epoch dan memori dari 5,11 menjadi 2,70 GB. Dengan 9 layer beku, RoBERTa masih mencapai 78,62%, atau 1,07 poin di atas DistilBERT penuh, dengan waktu training lebih singkat (7,49 berbanding 9,93 menit) dan memori lebih kecil (1,67 berbanding 2,64 GB). DistilBERT lebih sensitif karena pembekuan 3 dari 6 layer sudah menurunkan macro-F1 sebesar 1,47 poin, dan pembekuan seluruh layer membuat kedua model jatuh ke kisaran 65%. Latensi hampir tidak berubah (7,80–8,41 ms pada RoBERTa dan 3,91–4,23 ms pada DistilBERT; $p_{\text{Holm}} = 0{,}079$).

C. Pengaruh Parent Comment

Friedman test menunjukkan perbedaan macro-F1 di antara ketiga input ($p = 0{,}009$, $W = 0{,}78$). Seperti terlihat pada Gambar 2, parent menaikkan macro-F1 kedua model, yaitu 1,10 dan 0,69 poin dengan early fusion serta 0,78 dan 0,72 poin dengan late fusion pada RoBERTa dan DistilBERT. Keempat kenaikan signifikan menurut paired t-test dan McNemar. Tambahan biaya early fusion kecil: waktu training hanya 1,15–1,16 kali, latensi batch 1 dan memori hampir tetap, dan hanya latensi per contoh pada batch 32 yang naik sekitar dua kali.

Manfaat parent tidak merata. Pada 10.737 comment yang membuat model comment saja RoBERTa ragu, early fusion menaikkan macro-F1 RoBERTa sebesar 8,18 poin, tetapi hanya 0,25 poin pada comment yang diprediksi dengan yakin. Kenaikan pada comment 1–3 kata (2,59 poin) juga lebih besar

Tabel III
SKOR DATA UJI DAN BIAYA KOMPUTASI KONFIGURASI UTAMA

Input	Model	Skor data uji (%) Accuracy	Precision	Recall	F1	Macro-F1	Training (menit/epoch)	Latensi (ms) bs 1	bs 32	Memori (GB)
Comment saja	DistilBERT	76,88 ± 0,08	76,94 ± 0,65	75,80 ± 1,17	76,36 ± 0,29	76,87 ± 0,08	8,56	4,19	0,15	2,63
	RoBERTa	78,53 ± 0,07	78,33 ± 0,36	77,99 ± 0,46	78,16 ± 0,05	78,52 ± 0,06	16,61	8,42	0,31	5,09
Early fusion	DistilBERT	77,58 ± 0,06	78,14 ± 1,11	75,70 ± 2,03	76,88 ± 0,53	77,55 ± 0,09	9,93	4,23	0,32	2,64
	RoBERTa	**79,63** ± 0,05	**79,37** ± 1,31	**79,32** ± 2,22	**79,32** ± 0,48	**79,62** ± 0,06	19,03	8,41	0,61	5,11
Late fusion	DistilBERT	77,60 ± 0,02	77,62 ± 0,07	76,61 ± 0,07	77,12 ± 0,02	77,59 ± 0,02	14,92	7,20	0,42	4,29
	RoBERTa	79,30 ± 0,02	78,82 ± 0,21	79,29 ± 0,39	79,06 ± 0,09	79,30 ± 0,02	28,82	15,06	0,83	8,38

Early dan late fusion memakai comment + parent. Skor adalah rata-rata ± simpangan baku dari seed 42, 43, dan 44, dan biaya dirata-ratakan dari run yang sama. Precision, recall, dan F1 dihitung untuk kelas sarkas. Latensi pada ukuran batch (bs) 32 dinyatakan per contoh.

Tabel IV
HASIL UJI HIPOTESIS PADA DATA UJI

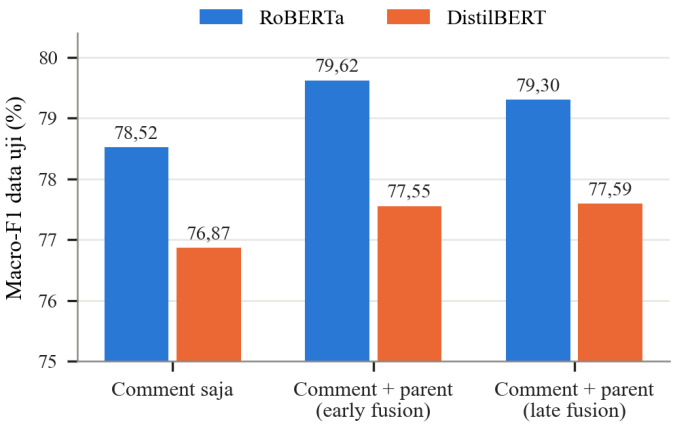
H_1	n	Δ	CI 95%	p_{Holm}	p_W	McN.
Performa: RoBERTa > DistilBERT						
Gabungan 3 input	9	1,81	1,65–1,97	<0,001	0,002	ya
Pembekuan layer: fine-tuning penuh > dibekukan sebagian						
RoBERTa, 6 layer	3	0,24	−0,02–0,49	0,028	–	tidak
RoBERTa, 9 layer	3	1,00	0,81–1,18	0,002	–	–
DistilBERT, 3 layer	3	1,47	1,28–1,66	0,002	–	–
Gabungan	9	0,90	0,48–1,32	0,002	0,002	–
Input: perbedaan ketiga input (Friedman)						
Comment, early, late	6	$W = 0{,}78$		0,009	–	–
Parent comment: comment + parent > comment saja						
Early, RoBERTa	3	1,10	0,83–1,37	0,004	–	ya
Early, DistilBERT	3	0,69	0,65–0,72	<0,001	–	ya
Late, RoBERTa	3	0,78	0,60–0,96	0,004	–	ya
Late, DistilBERT	3	0,72	0,53–0,92	0,004	–	ya
Early, gabungan	6	0,89	0,64–1,14	<0,001	0,016	–
Late, gabungan	6	0,75	0,67–0,83	<0,001	0,016	–
Strategi fusion: early fusion > late fusion						
RoBERTa	3	0,32	0,15–0,49	0,023	–	ya
DistilBERT	3	−0,04	−0,26–0,19	0,725	–	tidak
Gabungan	6	0,14	−0,08–0,36	0,158	0,109	–
Biaya: RoBERTa > DistilBERT (gabungan 3 input)						
Training (menit/epoch)	9	10,35	8,27–12,43	<0,001	0,002	–
Latensi bs 1 (ms)	9	5,42	4,01–6,82	<0,001	0,002	–
Memori (GB)	9	3,01	2,38–3,64	<0,001	0,002	–
Pendukung (Friedman)						
Ketiga seed	6	$W = 0{,}19$		0,311	–	–
Learning rate (validasi)	6	$W = 0{,}74$		0,004	–	–

n: jumlah pasangan atau blok; Δ: rata-rata selisih (poin macro-F1 atau satuan biaya); CI 95%: dua arah, sehingga dapat sedikit mencakup nol walaupun uji satu arah signifikan; p_{Holm}: p paired t-test atau Friedman setelah koreksi Holm; p_W: Wilcoxon; McN.: signifikan menurut McNemar dan Holm pada ketiga seed (–: tidak diuji).

daripada comment lebih dari 10 kata (0,71 poin), dan pada 5.886 comment (593 kalimat unik) yang muncul dengan label berbeda kenaikannya 2,73 poin. Meski begitu, parent memperbaiki rata-rata 6.236 prediksi RoBERTa per seed sekaligus merusak 5.119 prediksi lain.

D. Strategi Fusion Terbaik

Pada RoBERTa, early fusion unggul 0,32 poin dibanding late fusion (CI 95% 0,15–0,49, $p_{\text{Holm}} = 0{,}023$) dan juga signifikan menurut McNemar. Pada DistilBERT, keduanya setara (77,55% dan 77,59%), dan secara gabungan keunggulan early fusion tidak signifikan ($p_{\text{Holm}} = 0{,}158$). Late fusion merupakan konfigurasi termahal, dengan waktu training sekitar 1,5 kali, memori 1,62–1,64 kali, dan latensi batch 1 sebesar 1,70–1,79 kali early fusion.



Gambar 2. Macro-F1 data uji untuk setiap model dan konfigurasi input (rata-rata tiga seed). Sumbu vertikal dimulai dari 75% agar selisih antarkonfigurasi terlihat.

IV. PEMBAHASAN

A. Trade-off antara RoBERTa dan DistilBERT

RoBERTa terbukti lebih akurat, tetapi hanya 1,65–2,07 poin dengan biaya sekitar dua kali lipat, sehingga DistilBERT mempertahankan 97–98% macro-F1 RoBERTa dengan kira-kira setengah sumber daya. Rasio biaya ini hampir sama pada ketiga input, sehingga kemungkinan besar ditentukan oleh ukuran model. RoBERTa cocok bila akurasi menjadi prioritas, misalnya analisis offline, sedangkan DistilBERT cocok bila latensi dan memori terbatas, seperti alat moderasi yang memproses comment terus-menerus.

B. Pembekuan Layer dan Distilasi

Jumlah layer yang dibekukan berpengaruh terhadap performa, tetapi tidak linear. Pembekuan separuh layer RoBERTa hanya mengurangi 0,24 poin, sementara waktu training turun 45% dan memori 47%, sejalan dengan [16]. Penurunan jelas baru terlihat pada 9 layer dan sangat besar bila semua layer dibekukan, sehingga representasi pralatih tetap perlu difine-tune. DistilBERT turun lebih cepat, kemungkinan karena layernya lebih sedikit. Pembekuan hanya menghemat biaya training sehingga cocok untuk model yang sering dilatih ulang, sedangkan DistilBERT menghemat biaya inferensi.

C. Peran Parent Comment

Parent terbukti meningkatkan performa kedua model, walaupun rata-rata hanya sekitar satu poin karena sebagian besar comment sudah dapat dipahami dari isinya sendiri. Peran parent terasa saat comment ambigu, misalnya balasan ";)" yang muncul 68 kali di data uji dan hanya enam yang sarkas. Sebagai balasan untuk "Sarcasm doesn't translate well through text. Haha" comment ini sarkas, tetapi untuk "What is your Guilty Pleasure?" tidak, padahal tanpa parent model pasti memberi prediksi yang sama. Kenaikan ini jauh lebih kecil daripada laporan Dubey dkk. (7,1 poin [13] dan 6,8 poin [8]) yang memakai 7.370 sampel tanpa tanda baca dan huruf kapital, kondisi yang mungkin membuat model lebih bergantung pada parent.

D. Early Fusion dan Late Fusion

Early fusion dipilih sebagai strategi terbaik karena lebih akurat pada RoBERTa, setara pada DistilBERT, dan jauh lebih murah. Pada early fusion, token comment dapat memperhatikan kata tertentu di parent di setiap layer, sedangkan pada late fusion kedua teks diringkas dulu menjadi vektor. Karena sarkasme sering bergantung pada frasa tertentu di parent, late fusion kurang menguntungkan, meskipun mungkin berguna bila satu parent dibalas banyak comment.

E. Perbandingan dengan Penelitian Lain dan Keterbatasan

Skor yang lebih tinggi pada [13] (F1 95,6%) dan [14] (0,917) diperoleh dengan ukuran data, prapemrosesan, dan protokol evaluasi yang berbeda, dan tidak ada yang menyebutkan apakah potongan "/s" (Bagian II-A) dibuang. Rasio biayanya justru sejalan: waktu training RoBERTa pada SARC di [13] 1,76 kali DistilBERT (8,1 dan 4,6 jam), sedangkan di sini 1,92–1,94 kali.

Penelitian ini memiliki beberapa keterbatasan. Pertama, training dibatasi tiga epoch, padahal 24 dari 29 run final mencapai skor validasi terbaik pada epoch terakhir. Kedua, hanya satu dataset dipakai dan labelnya berasal dari penanda "/s", sehingga comment sarkas tanpa penanda tercatat bukan sarkas [5]. Ketiga, model yang dibekukan memakai learning rate fine-tuning penuh, model beku penuh hanya memakai satu seed, dan setiap uji per konfigurasi hanya memiliki tiga pasangan. Terakhir, large language model tidak disertakan dan efisiensi hanya diukur pada satu GPU.

V. Kesimpulan

RoBERTa terbukti lebih akurat daripada DistilBERT dalam deteksi sarkasme pada SARC, tetapi keunggulannya hanya sekitar dua poin macro-F1 dengan biaya komputasi kira-kira dua kali lipat. Jumlah layer yang dibekukan memengaruhi performa, namun setengah layer RoBERTa dapat dibekukan dengan penurunan sangat kecil untuk menghemat biaya training. Parent comment meningkatkan performa kedua model, dan early fusion menjadi strategi terbaik karena paling akurat pada RoBERTa dan lebih hemat daripada late fusion. RoBERTa dengan early fusion disarankan bila akurasi menjadi prioritas, sedangkan DistilBERT dengan early fusion cocok bila latensi dan memori terbatas. Penelitian selanjutnya dapat memperpanjang training, mencari learning rate khusus untuk model yang dibekukan, menguji dataset lain, dan membandingkan dengan large language model.

Daftar Pustaka

[1] O. Prakash, "Sarcasm detection for sentiment analysis using deep learning enhancement," *Procedia Computer Science*, vol. 258, pp. 203–212, 2025.

[2] R. Dhumpati, A. Sasi, S. J. Basha, S. Vadhri, P. Saroja, S. Alluri, and R. Vatambeti, "Enhancing sarcasm detection in sentiment analysis for cyberspace safety using advanced deep learning techniques," *Scientific Reports*, vol. 15, p. 22681, 2025.

[3] V. Grover and H. Banati, "An emoji centric approach to sarcasm detection in online discourse," *Scientific Reports*, vol. 16, p. 3891, 2026.

[4] R. Jiménez Castro, J. P. Sánchez-Solís, V. García Jiménez, G. Rivera Zárate, and R. Florencia Juárez, "A comparative study of bert-based models for sarcasm detection in social media texts," *International Journal of Combinatorial Optimization Problems and Informatics*, vol. 17, no. 2, pp. 378–390, 2026.

[5] M. Khodak, N. Saunshi, and K. Vodrahalli, "A large self-annotated corpus for sarcasm," in *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*. Miyazaki, Japan: European Language Resources Association (ELRA), 2018.

[6] S. Hao, J. Yao, C. Shi, Y. Zhou, S. Xu, D. Li, and Y. Cheng, "Enhanced semantic representation learning for sarcasm detection by integrating context-aware attention and fusion network," *Entropy*, vol. 25, no. 6, p. 878, 2023.

[7] T. Shangipour Ataei, S. Javdan, and B. Minaei-Bidgoli, "Applying transformers and aspect-based sentiment analysis approaches on sarcasm detection," in *Proceedings of the Second Workshop on Figurative Language Processing*, 2020, pp. 67–71.

[8] P. Dubey, P. Dubey, and P. N. Bokoro, "Unpacking sarcasm: A contextual and transformer-based approach for improved detection," *Computers*, vol. 14, no. 3, p. 95, 2025.

[9] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, "RoBERTa: A robustly optimized BERT pretraining approach," arXiv:1907.11692, 2019.

[10] M. Treviso, J.-U. Lee, T. Ji, B. van Aken, Q. Cao, M. R. Ciosici, M. Hassid, K. Heafield, S. Hooker, C. Raffel, P. H. Martins, A. F. T. Martins, J. Z. Forde, P. Milder, E. Simpson, N. Slonim, J. Dodge, E. Strubell, N. Balasubramanian, L. Derczynski, I. Gurevych, and R. Schwartz, "Efficient methods for natural language processing: A survey," *Transactions of the Association for Computational Linguistics*, vol. 11, pp. 826–860, 2023.

[11] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "DistilBERT, a distilled version of BERT: Smaller, faster, cheaper and lighter," arXiv:1910.01108, 2019.

[12] M. A. Ullah, R. Sultana, S. H. Chowdhury, and F. A. Laila, "Advanced sarcasm detection using transformer-based models: Analyzing variations in formal and informal languages," *Applied Computational Intelligence and Soft Computing*, vol. 2026, p. 8761185, 2026.

[13] P. Dubey, A. Mishra, A. Singh, Murtuza, A. Chanchlani, and P. Dubey, "Efficient transformer architecture for sarcasm detection: A study on compression and performance," *Bulletin of Electrical Engineering and Informatics*, vol. 15, no. 1, pp. 557–567, 2026.

[14] L. Zhang, M. Faseeh, S. S. A. Naqvi, L. Hu, and A. Ghani, "Enhancing sarcasm detection on social media: A comprehensive study using llms and bert with multi-headed attention on sarc," *PLoS ONE*, vol. 20, no. 11, p. e0334120, 2025.

[15] Z. Han, C. Gao, J. Liu, J. Zhang, and S. Q. Zhang, "Parameter-efficient fine-tuning for large models: A comprehensive survey," *Transactions on Machine Learning Research*, 2024.

[16] A. Ardakani, A. Haan, S. Tan, D. T. Popovici, A. Cheung, C. Iancu, and K. Sen, "SlimFit: Memory-efficient fine-tuning of transformer-based models using training dynamics," in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, 2024, pp. 6218–6236.

[17] D. Ulmer, C. Hardmeier, and J. Frellsen, "deep-significance: Easy and meaningful statistical significance testing in the age of neural networks," in *ML Evaluation Standards Workshop at the International Conference on Learning Representations (ICLR)*, 2022.

[18] R. Dror, L. Peled-Cohen, S. Shlomov, and R. Reichart, *Statistical Significance Testing for Natural Language Processing*, ser. Synthesis Lectures on Human Language Technologies. Cham, Switzerland: Springer, 2020.